Almacenes y Minería de Datos: Tarea 02

Zianya Nenetzi Trujillo Beltran
José Eduardo Cruz Campos
Paola Mildred Martínez Hidalgo

2026-03-19

Empresa y metodología de Minería de Datos

Cada integrante del equipo deberá elegir una empresa distinta en la que le gustaría trabajar e investigar qué metodología utiliza para desarrollar proyectos de Minería de Datos.

- **Zianya:** BBVA aplica CRISP-DM siguiendo 6 pasos:

  1. Comprensión del negocio y definición del objetivo
  2. Comprensión de los datos
  3. Análisis y preparación de los datos
  4. Modelado
  5. Obtención de resultados
  6. Despliegue

  Fuente: BBVA

- **José Eduardo:** Amazon utiliza KDD (Knowledge Discovery in Databases) que consta de 5 etapas:

1. Selección de datos relevantes
2. Preprocesamiento de datos
3. Transformación de datos
4. Minería de datos
5. Interpretación y evaluación
   Fuente: Amazon

- **Mildred:** Microsoft utiliza principalmente TDSP (Team Data Science Process) que consta de 5 etapas:

  1. Entendimiento del negocio
  2. Adquisición y comprensión de datos
  3. Modelado
  4. Implementación
  5. Aceptación
     Fuente: Microsoft

- **Eric:** Capital One, un banco estadounidense, diseña la metodología en función de que esté fuertemente cargada en automatización tanto en procesos de minería de datos como en procesos de machine learning, así como en la gestión de datos, en función de tener modelos que analizan tendencias de mercado y detección de fraudes o riesgos. Cada equipo es propietario de los recursos que utiliza, por lo que se encarga de su gestión y mantenimiento. Los datos siguen el siguiente ciclo de vida:

  1. Registro de Datos en un repositorio centralizado
  2. Clasificación de datos
  3. Ingesta
  4. Modelado
  5. Seguridad y Tokenización
  6. Personalización conforme a cliente
  7. Despliegue Fuente: Capital One

Descripción general del dataset

El dataset RNPDNO-22-08-2023 contiene información oficial sobre personas desaparecidas y no localizadas en México, publicada como dato abierto. Cada fila representa el reporte de una persona desaparecida.

- **Número de filas:** 116945

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

dataset = pd.read_csv("RNPDNO-22-08-2023.csv", encoding="latin-1")

df = pd.DataFrame(dataset)
num_files = df.shape[0] #obtenemos el numero de filas del csv

print(f"Numero de filas: {num_files}")
```

```
Numero de filas: 116945
```

- **Número de columnas:** 11

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

dataset = pd.read_csv("RNPDNO-22-08-2023.csv", encoding="latin-1")

df = pd.DataFrame(dataset)
num_columns = df.shape[1] #obtenemos el numero de columnas del csv

print(f"Numero de columnas: {num_columns}")
```

```
Numero de columnas: 11
```

- **Periodo de fechas cubierto:** Se cubrió desde el periodo del 01-05-1968 al 20-08-2023

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

dataset = pd.read_csv("RNPDNO-22-08-2023.csv", encoding="latin-1")

df = pd.DataFrame(dataset)

# eliminamos espacios en blanco de los nombres de las columnas
df.columns = df.columns.str.strip()
#metemos a una lista las fechas de desaparicion para despues obtener la fecha minima
df["Fecha de desaparición"] = pd.to_datetime( df["Fecha de desaparición"], format="%
fecha_min = df["Fecha de desaparición"].min()
fecha_max = df["Fecha de desaparición"].max()

print("Periodo:", fecha_min, "a", fecha_max)
```

```
Periodo: 1968-05-01 00:00:00 a 2023-08-20 00:00:00
```

- **Unidad de análisis:** En nuestro dataset, cada fila representa el reporte de una persona desaparecida, obteniendo datos como el ID del reporte (Consecutivo Reportes por Persona), Consecutivo registro (num de veces que se reportó), Nombre de la persona, Apellidos, Edad, Sexo, Nacionalidad, Fecha de desaparición, Entidad de desaparición, Autoridad que reportó.

Medidas descriptivas y análisis exploratorio de datos (EDA)

Diccionario de datos

Crear una tabla que incluya, para cada columna: - Nombre de la columna - Descripción - Tipo de dato (string, entero, float, fecha/hora, booleano) - Tipo estadístico: - Categórica nominal u ordinal - Numérica discreta o continua

COLUMNA	DESCRIPCIÓN	TIPO DE DATO	TIPO ESTADÍSTICO
Consecutivo Reportes por Persona	Identificador único de cada persona desaparecida.	int	Numerica Discreta
Consecutivo Registro	Número de veces que se reportó la persona	int	Numerica Discreta
Nombre	Nombre(s) de la persona reportada	str	Categorica Nominal
Primer Apellido	Primer apellido de la persona reportada	str	Categorica Nominal
Segundo Apellido	Segundo apellido de la persona reportada	str	Categorica Nominal
Edad	Edad de la persona reportada	int	Numérica Discreta
Sexo	Sexo de la persona reportada	str	Categorica Nominal
Nacionalidad	Nacionalidad de la persona reportada	str	Categorica Nominal
Fecha de desaparicion	Fecha que fue vista por última vez la persona reportada	fecha (datatime)	Categorica Discreta
Entidad de desaparición	Entidad donde desapareció la persona reportada	str	Categorica Nominal
Autoridad que reporto	Institución que realizó el reporte	str	Categorica Nominal

Figura 1: Tabla de columnas

Aplicación de CRISP-DM al dataset asignado

Business Understanding

Contexto / Escenario

México atraviesa una grave crisis de inseguridad con más de 110,965 casos registrados de personas desaparecidas y no localizadas, principalmente vinculadas a problemáticas estructurales como la violencia, el crimen organizado y la impunidad. Este fenómeno presenta características sistemáticas y afecta de manera diferenciada a diversos grupos

de la población. El presente análisis se sitúa en un contexto social y analítico, utilizando datos abiertos sobre personas desaparecidas en México. El dataset proporciona información relevante sobre características demográficas (edad, sexo, nacionalidad), así como variables temporales y geográficas (fecha y entidad de desaparición) y las autoridades responsables del reporte. El objetivo de este análisis es identificar estadísticas, tendencias y grupos vulnerables a lo largo del tiempo.

Situación problemática

Las desapariciones ocurren frecuentemente con la intervención directa e indirecta de agentes gubernamentales. Estos actores estatales podrían corresponder a una parte de una red de macro-criminalidad en donde se promueven los fines del crimen organizado. El contexto de impunidad en México ha contribuido a la crisis de desapariciones. La falta de información sobre desapariciones es usada para justificar la falta de rendición de cuentas y justicia. Al mirar estos casos más de cerca, se demuestra que oficiales gubernamentales no investigan las desapariciones de una manera oportuna y efectiva como la ley lo requiere. Esto se puede deber a la dificultad de tal investigación o al miedo a llevarla a cabo en un contexto de crímenes violentos. De forma alternativa, la falta de búsqueda o investigación ha sido usada para encubrir el involucramiento de los mismos agentes estatales. La falta de investigación efectiva y la ausencia de justicia perpetúan el ciclo de violencia y desapariciones, dejando a las víctimas y sus familias sin respuestas ni reparación.

Fuente: Desapariciones en México - University of Minnesota

Objetivo de análisis

El objetivo de este análisis es entender cómo se comporta el fenómeno de desapariciones en México.

Necesidades de información

En consecuencia, el problema inicial se puede formular así:

- ¿En qué entidades del país ocurren más desapariciones?
- ¿Existen patrones regionales o zonas de mayor riesgo?
- ¿Qué grupos de edad son más vulnerables?
- ¿Hay diferencias por sexo o nacionalidad?
- ¿Qué autoridades reportan más casos?
- ¿Cómo han evolucionado las desapariciones a lo largo del tiempo?

Data Understanding

A partir del escenario anterior, como equipo analítico se realiza una exploración inicial del dataset, evaluando la calidad de los datos, valores faltantes e inconsistencias, formulando preguntas como las siguientes:

Sobre estructura general del dataset

- ¿Cuántas filas y columnas tiene el dataset?
  (anteriormente vimos que tiene 116945 filas y 11 columnas)
- ¿Cuantas variables numéricas y categóricas hay?
  (notamos 3 variables numéricas: edad, consecutivo reportes por persona, consecutivo registro; y 8 variables categóricas: nombre, apellido paterno, apellido materno, sexo, nacionalidad, fecha de desaparición, entidad de desaparición, autoridad que reporta)
- ¿Existen registros duplicados, datos eliminados o filas incompletas?
- ¿Hay inconsistencias en los nombres de entidades o instituciones?

Sobre variables de entidades de desaparición

- ¿Cuáles son las entidades con más desapariciones?
- ¿Cómo se distribuyen las desapariciones a lo largo del tiempo?

Sobre variables de las instituciones que reportan desapariciones

- ¿Qué autoridades reportan la mayor cantidad de desapariciones?
- ¿Existen instituciones con mayor registros inconsistentes o muy pocos reportes?

Sobre variables características de las personas desaparecidas

- ¿Qué grupos de edad son más vulnerables a las desapariciones?
- ¿Qué grupos de sexo y nacionalidad presentan más casos de desaparición?

Sobre la calidad de los datos

- ¿Qué porcentaje de datos faltantes hay en cada columna?

Data Preparation

Antes de emplear cualquier técnica de limpieza, necesitamos analizar los datos eliminados, duplicados y vacíos, para contestar las siguientes preguntas:

- **¿Cuál es el porcentaje de faltantes de cada columna?**

```
import numpy as np
import pandas as pd

dataset = pd.read_csv("RNPDNO-22-08-2023.csv", encoding="latin-1")
df = pd.DataFrame(dataset)

#limpiamos el dataset, convirtiendo a NaN en un csv copia
faltantes = [ "", " ", "NA", "N/A", "SE DESCONOCE", "ELIMINADO 1", "ELIMINADO 2", "EL
df_limpio = df.replace(faltantes, np.nan)
df_limpio = df_limpio.replace(r"ELIMINADO.*", np.nan, regex=True)
df_limpio.to_csv("dataset_limpio.csv", index=False)
```

```
# Obtenemos el porcentaje de valores faltantes por columna
faltantes_abs = df_limpio.isna().sum() #convertimos valores a T/F, y sumamos por colu
porcentaje_col = (df_limpio.isna().sum() / len(df_limpio)) * 100 #porcentaje de falta
num_faltantes_col = df_limpio.isna().sum() #numero de faltantes por columna
resumen = pd.DataFrame({
    "Número de faltantes": num_faltantes_col,
    "Porcentaje ": porcentaje_col.round(0).astype(int).astype(str) + "%"
})
print(resumen.to_string())
```

```
                                Número de faltantes Porcentaje
Consecutivo Reportes por Persona                 5980         5 %
Consecutivo Registro                                0         0 %
Nombre                                          37465        32 %
Primer Apellido                                 37487        32 %
Segundo Apellido                                38908        33 %
Edad                                            42022        36 %
Sexo                                            37460        32 %
Nacionalidad                                    45981        39 %
Fecha de desaparición                           93542        80 %
Entidad de desaparición                         38261        33 %
Autoridad que reportó                           38024        33 %
```

- **¿Cuál es el porcentaje de valores faltantes en general?**

```
import numpy as np
import pandas as pd

dataset = pd.read_csv("RNPDNO-22-08-2023.csv", encoding="latin-1")
df = pd.DataFrame(dataset)
```

```
#limpiamos el dataset, convirtiendo a NaN en un csv copia
faltantes = [ "", " ", "NA", "N/A", "SE DESCONOCE", "ELIMINADO 1", "ELIMINADO 2", "EL
df_limpio = df.replace(faltantes, np.nan)
df_limpio = df_limpio.replace(r"ELIMINADO.*", np.nan, regex=True)
df_limpio.to_csv("dataset_limpio.csv", index=False)

# Obtenemos el porcentaje total de valores faltantes en el dataset
total_celdas = df_limpio.shape[0] * df_limpio.shape[1]
total_faltantes = df_limpio.isna().sum().sum() #sumamos el total de datos faltantes e
porcentaje_total = (total_faltantes / total_celdas) * 100 # sacamos el porcentaje
print("")
print(f"Número total de datos faltantes: {total_faltantes}")
print(f"Porcentaje total de datos faltantes: {round(porcentaje_total)}%")
```

```
Número total de datos faltantes: 415130
Porcentaje total de datos faltantes: 32 %
```

- **¿Cuál es el patrón de ausencia?**

Se identifican distintos patrones de ausencia en el dataset. La variable fecha de desaparición tiene el mayor porcentaje de valores faltantes (80 %), lo que sugiere un patrón no aleatorio asociado a fallas en el registro. También existen casos con múltiples datos faltantes simultáneamente, especialmente en registros con varias columnas con el valor "ELIMINADO", indicando ausencia agrupada por fila. Por otra parte variables como edad, sexo y nacionalidad muestran un porcentaje faltante entre 30 % y 40 % de forma más dispersa, lo que puede apuntar a problemas de captura o diferencias entre fuentes. En conjunto, los datos faltantes responden a factores estructurales y no son completamente aleatorios.

- **¿Cuál sería el mecanismo de ausencia más probable?**

En el caso de la variable Fecha de desaparición su porcentaje de valores faltantes (80 %) indica un mecanismo de tipo MAR (Missing At Random), ya que su ausencia probablemente depende de factores como la institución que reporta, la entidad o el periodo de registro.

Por otro lado, los registros que contienen valores como "ELIMINADO" evidencian un mecanismo de tipo MNAR (Missing Not At Random), dado que la ausencia de información puede deberse a procesos intencionales de anonimización o censura.

Finalmente, variables como edad, sexo y nacionalidad presentan un comportamiento consistente con un mecanismo predominantemente MAR, posiblemente asociado a inconsistencias en la captura de datos o diferencias en la calidad de las fuentes.

Nota: La identificación del mecanismo de ausencia es crucial para determinar las estrategias de limpieza y análisis, ya que cada tipo de mecanismo requiere enfoques diferentes para manejar los datos faltantes sin introducir sesgos significativos.

- MCAR: faltan datos al azar
- MAR: faltan datos dependiendo de otra variable
- MNAR: faltan datos porque justo ese dato es problemático

- **¿Qué decisión se puede tomar respecto a los valores faltantes y por qué?**

No podemos eliminar observaciones incompletas puesto que la mayoría el 80 % de la columna de Fecha de desaparición está incompleta, por lo que perderíamos el 80 % de la información total. La imputación simple mediante media, mediana o moda no resulta adecuada para la variable Fecha de desaparición puesto que generaría falsas concentraciones de datos en determinados periodos de tiempo, distorsionando las tendencias reales y comprometiendo la validez del análisis. Por lo que se opta por mantener los valores faltantes remplazándolos como NaN para mantener la integridad de los datos disponibles y evitar sesgos a través de imputaciones incorrectas. Y eliminamos las filas que tienen valores como "ELIMINADO" en todas sus columnas, ya que estas filas no aportan información útil para el análisis y su presencia podría generar ruido o confusión en los resultados. Finalmente, el poco porcentaje de registros

con fecha disponible se pueden utilizar para el análisis temporal, permitiendo estudiar tendencias y evolución en el tiempo además de el análisis demográfico, geográfico e institucional que se puede realizar con la mayoría del dataset, maximizando el aprovechamiento de la información disponible.

- **¿Cómo podemos encontrar registros duplicados?**

Para encontrar registros duplicados primero necesitamos limpiar el dataset con el siguiente codigo:

```
import pandas as pd
import numpy as np

# 1. Cargamos dataset
dataset = pd.read_csv("RNPDNO-22-08-2023.csv", encoding="latin-1")
print("Total de registros iniciales:", len(dataset))

# 2. Reemplazamos vacíos por NaN
dataset = dataset.replace(r'^\s*$', np.nan, regex=True)

# 3. Reemplazamos "ELIMINADO" por NaN
dataset = dataset.replace(to_replace="ELIMINADO.*", value=np.nan, regex=True)

# 4. Eliminamos filas donde todas las columnas relevantes son NaN (registros ELIMINAD
columnas_relevantes = [
    "Nombre", "Primer Apellido", "Segundo Apellido",
    "Fecha de desaparición", "Entidad de desaparición", "Autoridad que reportó"
]
dataset = dataset.dropna(subset=columnas_relevantes, how="all")

# Normalizar texto
cols_texto = ["Sexo", "Nacionalidad", "Entidad de desaparición", "Autoridad que repor
```

```
for col in cols_texto:
    dataset[col] = dataset[col].str.upper().str.strip()

# guardamos parte del dataset limpio
dataset.to_csv("dataset_limpio.csv", index=False)
```

```
Total de registros iniciales: 116945
```

Ahora, para encontrar duplicados utilizamos el sig codigo:

```
import pandas as pd
import numpy as np

# 1. Cargamos dataset
dataset = pd.read_csv("RNPDNO-22-08-2023.csv", encoding="latin-1")



# 5. Convertimos la columna de consecutivo a entero nullable
dataset["Consecutivo Reportes por Persona"] = dataset["Consecutivo Reportes por Perso

# 6. Buscamos si hay duplicados
duplicados = dataset[dataset.duplicated(
    subset=[
        "Nombre", "Primer Apellido", "Segundo Apellido",
        "Fecha de desaparición", "Entidad de desaparición", "Autoridad que reportó"
    ],
    keep=False
)]

# print("Ejemplo de registros duplicados:")
# print(duplicados.head(20))
```

```python
print("Duplicados encontrados:", len(duplicados))

# 7. Eliminamos duplicados
dataset = dataset.drop_duplicates(
    subset=[
        "Nombre", "Primer Apellido", "Segundo Apellido",
        "Fecha de desaparición", "Entidad de desaparición", "Autoridad que reportó"
    ],
    keep="first"
)

# 8. Confirmamos que ya no hay duplicados
duplicados = dataset[dataset.duplicated(
    subset=[
        "Nombre", "Primer Apellido", "Segundo Apellido",
        "Fecha de desaparición", "Entidad de desaparición", "Autoridad que reportó"
    ],
    keep=False
)]
print("Nuevos duplicados encontrados:", len(duplicados))

# 9. Guardar dataset limpio
dataset.to_csv("dataset_limpio.csv", index=False)
print("Dataset guardado como dataset_limpio.csv")
print("Total de registros finales:", len(dataset))
```

```
Duplicados encontrados: 37842
Nuevos duplicados encontrados: 0
Dataset guardado como dataset_limpio.csv
Total de registros finales: 79295
```

- **¿Qué acciones se tomaron respecto a los registros duplicados y por**

qué?

Eliminamos únicamente los registros que coincidieran en nombre, apellido paterno, materno, fecha de desaparición, Entidad de desaparición y Autoridad que reportó puesto que el nombre y apellido no son suficiente para eliminar registros duplicados pues esa persona puede tener reportes en diferentes instituciones.

Modelling

Se proponen técnicas como clustering y análisis de series de tiempo para el análisis del fenómeno. A continuación, se muestra una implementación inicial de ambos modelos para identificar patrones en la edad y volumen de desapariciones.

1. Análisis de Series de Tiempo

Este modelo busca identificar la tendencia temporal del volumen de personas desaparecidas a lo largo de los meses.

```
import pandas as pd
import matplotlib.pyplot as plt

# Asumiendo que df_limpio es nuestro dataframe después del Data Preparation
# Agrupamos por año y mes usando la fecha de desaparición
if "Fecha de desaparición" in df_limpio.columns:
    df_limpio["Fecha de desaparición"] = pd.to_datetime(df_limpio["Fecha de desaparic

    df_ts = df_limpio.dropna(subset=["Fecha de desaparición"]).copy()

    serie_tiempo = df_ts.groupby(df_ts["Fecha de desaparición"].dt.to_period("M")).si
    serie_tiempo["Fecha de desaparición"] = serie_tiempo["Fecha de desaparición"].dt.

    plt.figure(figsize=(12, 6))
```

```
    plt.plot(serie_tiempo["Fecha de desaparición"], serie_tiempo["Total"], marker='',
    plt.title("Tendencia Histórica de Desapariciones (Agrupado por Mes)")
    plt.xlabel("Año y Mes")
    plt.ylabel("Cantidad de Desapariciones")
    plt.grid(True)
    plt.show()
else:
    print("La columna 'Fecha de desaparición' no está disponible para analizar.")
```

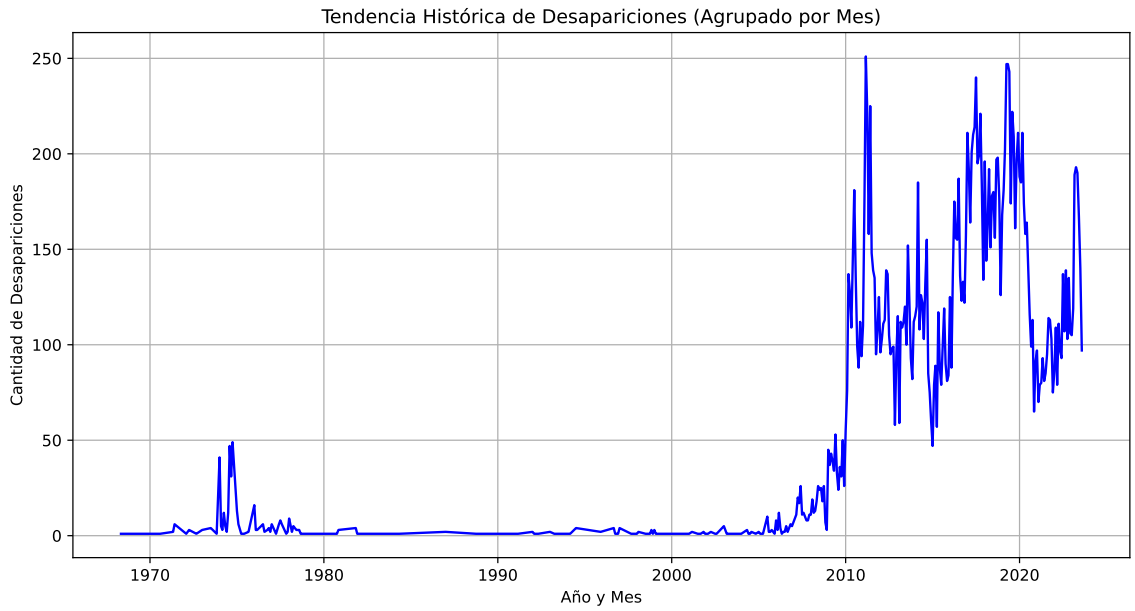

2. Clustering (K-Means)

Agruparemos las entidades federativas (estados) con base en dos características numéricas: la **cantidad total de desapariciones** y la **edad promedio** de los desaparecidos.

```
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
```

```
import seaborn as sns

if "Entidad de desaparición" in df_limpio.columns and "Edad" in df_limpio.columns:
    df_limpio["Edad"] = pd.to_numeric(df_limpio["Edad"], errors="coerce")

    df_cluster = df_limpio.groupby("Entidad de desaparición").agg({
        "Edad": "mean",
        "Consecutivo Registro": "count"
    }).reset_index()

    df_cluster.rename(columns={"Consecutivo Registro": "Total_Desapariciones"}, inpla
    df_cluster.dropna(inplace=True)

    scaler = StandardScaler()
    X_scaled = scaler.fit_transform(df_cluster[["Edad", "Total_Desapariciones"]])

    kmeans = KMeans(n_clusters=4, random_state=42)
    df_cluster["Cluster"] = kmeans.fit_predict(X_scaled)

    # Visualizar los clusters
    plt.figure(figsize=(10, 6))
    sns.scatterplot(data=df_cluster, x="Edad", y="Total_Desapariciones", hue="Cluster

    plt.title("Clustering de Entidades: Volumen de Desapariciones vs Edad Promedio")
    plt.xlabel("Edad Promedio")
    plt.ylabel("Total de Desapariciones")

    for i, txt in enumerate(df_cluster["Entidad de desaparición"]):
        if df_cluster["Total_Desapariciones"][i] > df_cluster["Total_Desapariciones"]
            plt.annotate(txt, (df_cluster["Edad"][i], df_cluster["Total_Desapariciones
```

```
    plt.show()
else:
    print("Faltan columnas numéricas requeridas para el clustering.")
```

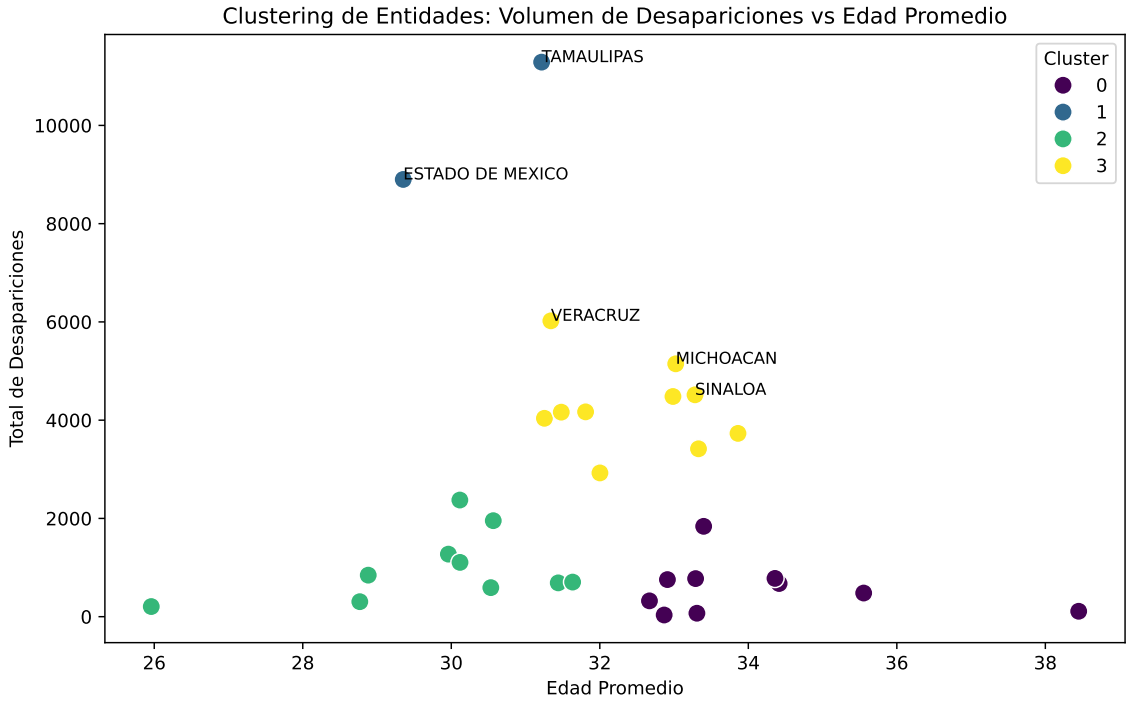

3. Clasificación con Árboles de Decisión

Este modelo ayuda a identificar reglas que separan a las personas desaparecidas según su sexo, utilizando su Edad y el Estado donde desaparecieron.

```
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.preprocessing import LabelEncoder

if "Sexo" in df_limpio.columns and "Entidad de desaparición" in df_limpio.columns and
    df_tree = df_limpio.dropna(subset=["Edad", "Sexo", "Entidad de desaparición"]).co
```

```
    df_tree = df_tree[df_tree["Sexo"].isin(["HOMBRE", "MUJER"])]

    le_sexo = LabelEncoder()
    df_tree["Sexo_encoded"] = le_sexo.fit_transform(df_tree["Sexo"])

    le_entidad = LabelEncoder()
    df_tree["Entidad_encoded"] = le_entidad.fit_transform(df_tree["Entidad de desapar

    X = df_tree[["Edad", "Entidad_encoded"]]
    y = df_tree["Sexo_encoded"]

    clf = DecisionTreeClassifier(max_depth=3, random_state=42, class_weight="balanced
    clf.fit(X, y)

    plt.figure(figsize=(16, 8))
    plot_tree(clf,
              feature_names=["Edad", "Entidad (Codificada)"],
              class_names=le_sexo.classes_,
              filled=True,
              rounded=True,
              fontsize=10,
              proportion=True) # Mostrar en proporciones para mayor legibilidad
    plt.title("Árbol de Decisión: Reglas del perfil de Desaparición por Sexo")
    plt.show()
else:
    print("Faltan columnas necesarias para ejecutar el Árbol de Decisión.")
```

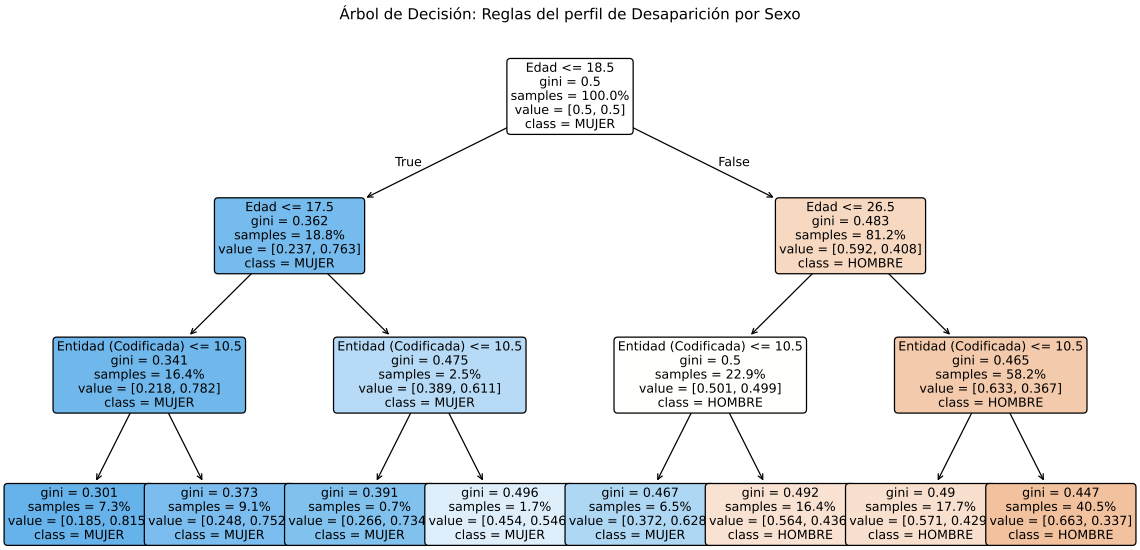

4. Predicción de Nacionalidad (Random Forest)

Este modelo evalúa la importancia de variables demográficas y geográficas para predecir si una persona reportada es de origen extranjero o mexicano, ayudando a detectar patrones de migración vulnerada.

```
from sklearn.ensemble import RandomForestClassifier
import numpy as np

if "Nacionalidad" in df_limpio.columns and "Entidad de desaparición" in df_limpio.col
    df_rf = df_limpio.dropna(subset=["Edad", "Sexo", "Entidad de desaparición", "Naci

    # Binarizamos Nacionalidad: 0 = Mexicana, 1 = Extranjera/Otra
    es_mexicano = df_rf["Nacionalidad"].str.contains("MEXICAN", case=False, na=False)
    df_rf["Es_Extranjero"] = np.where(es_mexicano, 0, 1)

    df_rf = df_rf[df_rf["Sexo"].isin(["HOMBRE", "MUJER"])]
```

```
    le_sexo = LabelEncoder()
    df_rf["Sexo_encoded"] = le_sexo.fit_transform(df_rf["Sexo"])

    le_entidad = LabelEncoder()
    df_rf["Entidad_encoded"] = le_entidad.fit_transform(df_rf["Entidad de desaparici

    X = df_rf[["Edad", "Sexo_encoded", "Entidad_encoded"]]
    y = df_rf["Es_Extranjero"]

    # Entrenamiento de Bosque Aleatorio balanceado para manejar grupos minoritarios (
    rf = RandomForestClassifier(n_estimators=50, max_depth=5, class_weight="balanced'
    rf.fit(X, y)

    # Obtenemos la importancia de cada variable (cuál predice mejor el origen)
    importances = rf.feature_importances_
    features = ["Edad", "Sexo", "Entidad"]

    plt.figure(figsize=(8, 5))
    plt.barh(features, importances, color='teal')
    plt.title("Importancia de Factores para Predecir Población Extranjera")
    plt.xlabel("Nivel de Importancia (Importancia de Gini)")
    plt.show()
else:
    print("Faltan columnas necesarias para el modelo de Nacionalidad.")
```

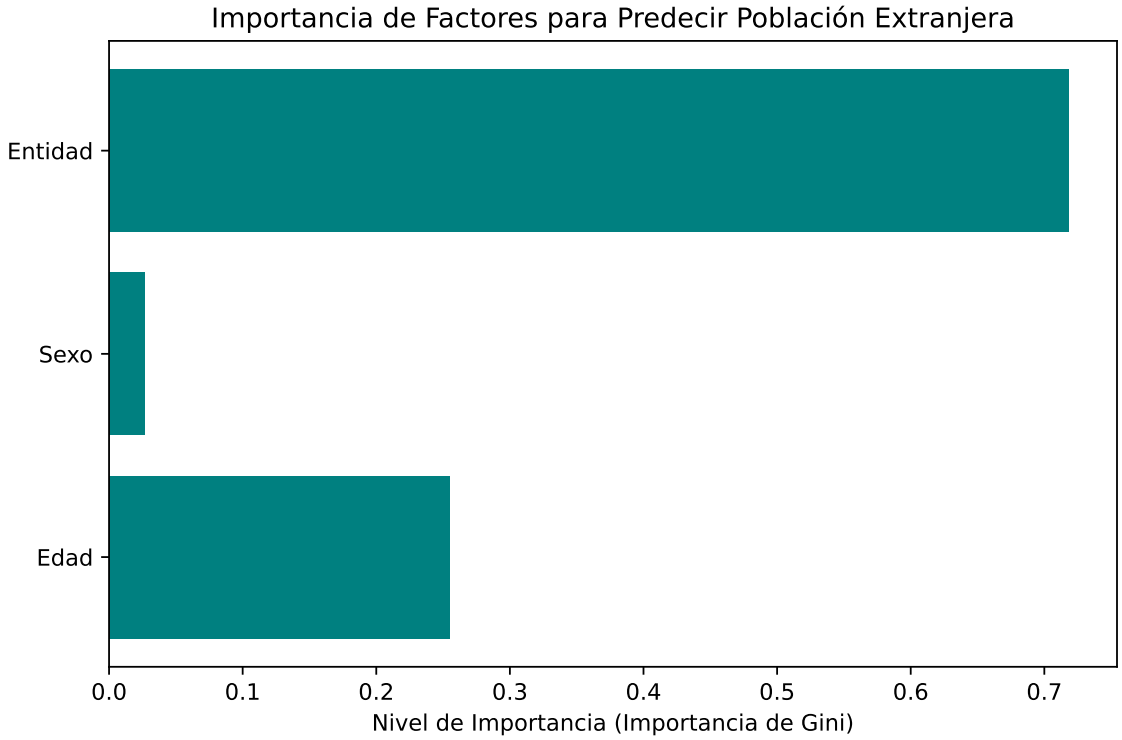

Evaluation

Con base en la implementación de los modelos y el EDA previo, se establecen las siguientes conclusiones y observaciones para el cumplimiento de los **Objetivos del Negocio**:

1. **Cumplimiento de las Necesidades de Información:**
   - Los diversos modelos (Clustering, Árboles) consiguieron responder activamente "qué entidades corren mayor riesgo" y "cuáles grupos son vulnerables (edad y género)". Las reglas visuales del árbol de decisión ayudan a los tomadores de decisiones a entender demográficamente los riesgos.
2. **Limitaciones por la Calidad de los Datos:**

- **Series de Tiempo y Fechas:** El análisis temporal, aunque permite observar picos institucionales de reportes, se encuentra profundamente sesgado. El haber documentado un 80 % de datos faltantes bajo un comportamiento `MAR` u ocultamiento `MNAR` indica que los valles en la gráfica de tiempo pueden no representar baja criminalidad, sino ineficiencia burocrática temporal o épocas de no-registro de las autoridades.

3. **Confiabilidad Técnica y Sesgos de Clase:**
   - **Random Forest (Nacionalidad):** El intento de predecir población extranjera devela un fuerte desequilibrio estructural (imbalance de clases). La evaluación de un modelo sobre estos datos no se puede confiar únicamente en su "Precisión" (Accuracy), ya que el ~98 % de personas siempre serán de origen mexicano en los registros. Sin embargo, permite evaluar mediante Importancia de Variables (Feature Importances) que factores como la geografía son sumamente determinantes para extranjeros vulnerados durante flujos migratorios.

En conjunto, el modelado extrajo valor real de los datos disponibles, no obstante, las fallas institucionales en la captura de registros dictan que estas conclusiones representan únicamente los crímenes efectivamente "reconocidos" y capturados, más no el volumen real no reportado, y se deben presentar bajo este contexto ético.

Deployment

El despliegue (*Deployment*) de este proyecto de Minería de Datos no concluye en la implementación de un software predictivo automatizado tradicional, sino en la **disponibilidad de inteligencia analítica y de datos limpios** para tomadores de decisiones, investigadores y ONGs.

Las acciones de despliegue para este análisis consisten en:

1. **Reporte Técnico y Reproducibilidad:** Integración de todo el flujo de trabajo (desde la carga de datos hasta la Evaluación) en este documento dinámico (`.qmd`). Al compilarse, despliega un reporte HTML o PDF con código reproducible.

2. **Suministro del Pipeline de Datos (Data Asset):** Exportación y publicación del conjunto de datos ya depurado (`dataset_limpio.csv`), garantizando que equipos externos puedan montar sus propios algoritmos sobre una base con formatos homologados (fechas numéricas, strings estandarizados y nulos declarados bajo la metodología MAR/MNAR).
3. **Despliegue de Reglas de Decisión (Insights):** Las reglas extraídas en la fase de modelaje (el Árbol de Decisión y la segmentación de K-Means) pueden ser desplegadas como *alertas paramétricas* en sistemas de información del gobierno. Por ejemplo, al recibirse un nuevo reporte en la Fiscalía, el sistema puede alertar automáticamente sobre un riesgo agudo si la persona ingresada cruza los umbrales de alta vulnerabilidad detectados por nuestros modelos demográficos.

Cálculo de medidas con visualizaciones e interpretación

Se clasificaron las variables del dataset en cuantitativas y cualitativas con el fin de determinar las medidas y visualizaciones adecuadas, consultar la Figura 1.

- **Cualitativas**
  - *Nominales:* sexo, nacionalidad, entidad, autoridad que reportó
  - *Ordinales:* no tenemos.
- **Cuantitativas**
  - *Discretas:* consecutivo registro, edad
  - *Continuas:* no tenemos

Nota: La variable fecha de desaparición se clasifica como una variable temporal, ya que representa un punto específico en el tiempo y no una cantidad medible.

Sin embargo, esta variable puede transformarse en nuevas variables derivadas, como año y mes, las cuales permiten realizar análisis cuantitativos y categóricos. Por

ejemplo, el mes puede utilizarse como variable categórica ordinal para identificar patrones estacionales en las desapariciones.

Nota: Las variables nombre, primer apellido, segundo apellido y consecutivo de reportes por persona (ID) fueron clasificadas como variables identificadoras.

Estas variables no fueron consideradas en el análisis estadístico, ya que su función es únicamente distinguir registros individuales.

Asimismo, no son susceptibles de análisis mediante medidas estadísticas ni aportan valor en la generación de visualizaciones, debido a que no permiten identificar patrones, tendencias o relaciones significativas dentro del dataset.

Medidas de localización

Para el análisis de las medidas de localización se utilizó la variable edad, calculando la media, mediana y moda. A partir del histograma, se observa que la edad con mayor frecuencia de desaparición es de 18 años (moda), lo cual sugiere una concentración preocupante en la población adolescente.

Asimismo, la mediana (29) es menor que la media (31.7), lo que indica que la distribución presenta un sesgo hacia la derecha. Esto implica que existen algunos casos de mayor edad que elevan el promedio.

Por otro lado, los percentiles permiten comprender mejor la distribución de la variable. Por ejemplo, el percentil 90 indica que el 90 % de las personas desaparecidas tiene una edad menor o igual a 52 años. Estas medidas son útiles para identificar valores extremos y analizar la dispersión de los datos.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Cargar dataset limpio
```

```
df = pd.read_csv('dataset_limpio.csv', encoding='latin1')
df['Edad'] = pd.to_numeric(df['Edad'], errors='coerce')
edad = df['Edad'].dropna().values

# Medidas de localización
mean   = edad.mean()
median = np.median(edad)

# Moda aproximada: centro del bin con mayor frecuencia
bins = 50
counts, bin_edges = np.histogram(edad, bins=bins)
max_bin_idx = np.argmax(counts)
mode_approx = 0.5 * (bin_edges[max_bin_idx] + bin_edges[max_bin_idx + 1])

print(f"Media            = {mean:.2f} años")
print(f"Mediana          = {median:.0f} años")
print(f"Moda (aprox)     = {mode_approx:.0f} años")

# Histograma con líneas de localización
plt.figure()
plt.hist(edad, bins=bins, alpha=0.45, edgecolor="white")
plt.title("Personas desaparecidas en México: histograma de edad")
plt.xlabel("Edad (años)")
plt.ylabel("Frecuencia")

plt.axvline(mean,        color="tab:blue",   linestyle="--", linewidth=2, label=f"Med
plt.axvline(median,      color="tab:orange", linestyle="-",  linewidth=2, label=f"Med
plt.axvline(mode_approx, color="tab:red",  linestyle=":",  linewidth=2, label=f"Moda

plt.legend()
plt.tight_layout()
```

```python
plt.show()

# ECDF para percentiles y cola
x_sorted = np.sort(edad)
y = np.arange(1, x_sorted.size + 1) / x_sorted.size

plt.figure()
plt.step(x_sorted, y, where="post")
plt.title("Personas desaparecidas en México: ECDF de edad")
plt.xlabel("Edad (años)")
plt.ylabel("Proporción acumulada")
plt.ylim(0, 1.01)
plt.tight_layout()
plt.show()

# Percentiles
p25, p50, p75, p90, p95 = np.quantile(edad, [0.25, 0.50, 0.75, 0.90, 0.95])
print(f"P25={p25:.0f} años,  P50={p50:.0f} años,  P75={p75:.0f} años")
print(f"P90={p90:.0f} años,  P95={p95:.0f} años")
```

```
Media            = 31.71 años
Mediana          = 29 años
Moda (aprox)     = 18 años
```

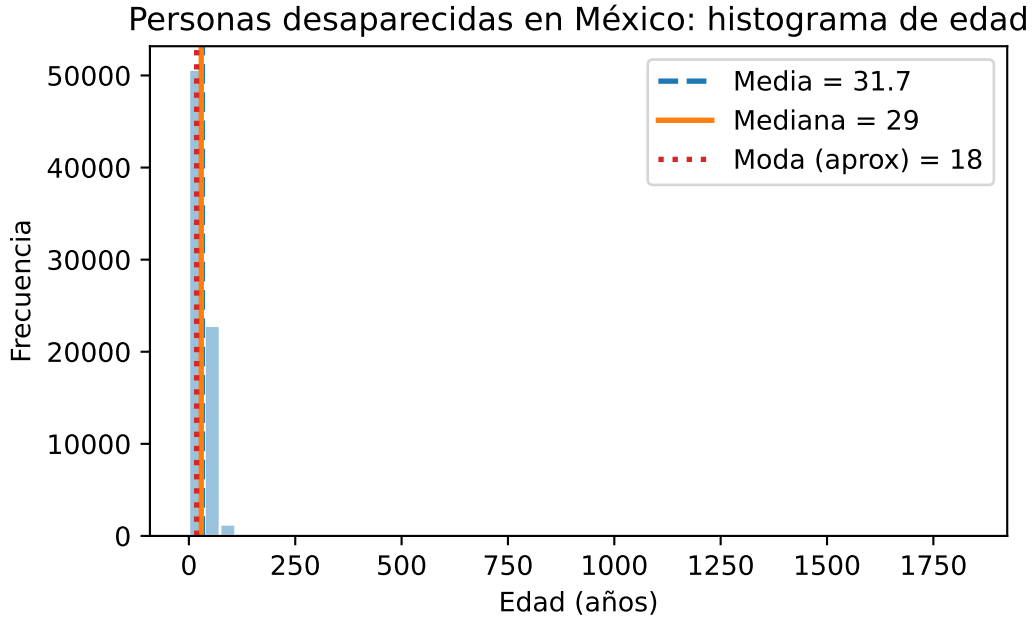

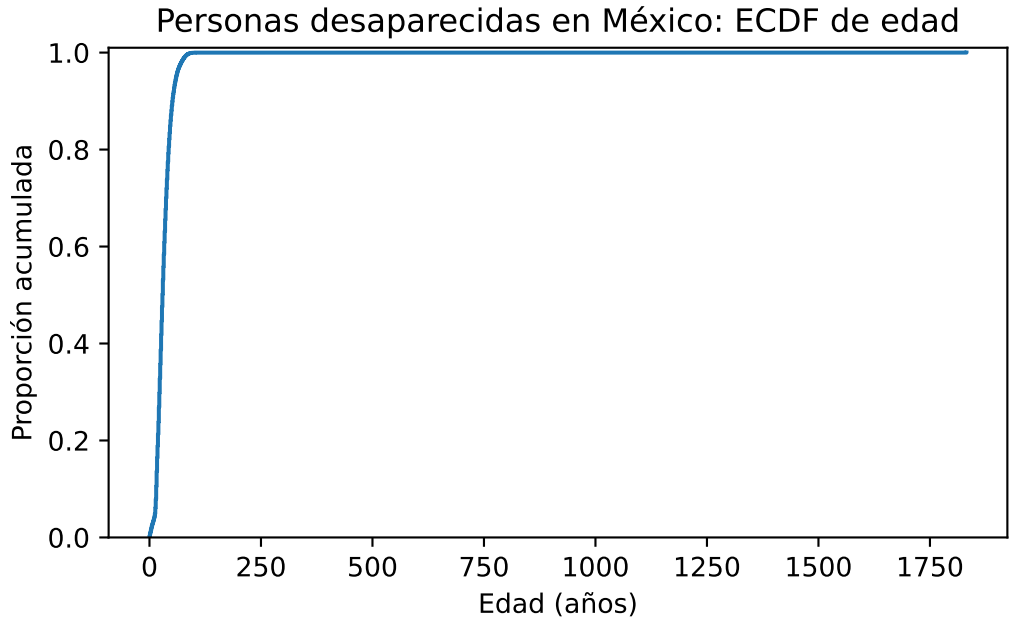


```
P25=21 años,  P50=29 años,  P75=40 años
P90=52 años,  P95=60 años
```

Finalmente, en ambas gráficas se observa claramente la presencia de un sesgo. Esto se debe a un valor atípico considerablemente alejado del resto (1832), lo cual puede confirmarse con el siguiente código.

```
print(df['Edad'].max())
```

```
1832.0
```

Medidas de variabilidad

Varianza y desviación estándar

Para interpretar la varianza nos ayudamos de la desviación estandar, en este caso tenemos una desviación estándar de 17 años, esto significa que las edades de las personas registradas como desaparecidas se dispersan, en promedio, aproximadamente 17 años por encima o por debajo de la media. Esto implica que el rango típico de edades oscila entre los 14 años $(31 - 17)$ y los 48 años $(31 + 17)$, abarcando desde adolescentes hasta adultos de mediana edad como el perfil más frecuente.

Esto refleja que la desaparición de personas en México no se limita a un grupo específico, sino que afecta a individuos en distintas edades, sin embargo se puede ver una mayor concentración en edades jóvenes, lo cual vimos también con la moda, esto sugiere que la población adolescente y adulta joven enfrenta un riesgo particularmente elevado.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Cargar CSV limpio
df = pd.read_csv('dataset_limpio.csv', encoding='latin1')
df['Edad'] = pd.to_numeric(df['Edad'], errors='coerce')
```

```python
edad = df['Edad'].dropna()

# Medidas de variabilidad
varianza = edad.var(ddof=1)
desv_std = edad.std(ddof=1)
media    = edad.mean()

print(f"Varianza:             {varianza:.4f} años")
print(f"Desviación estándar: {desv_std:.4f} años")
print(f"Media:                {media:.2f} años")

# Gráfica
fig, ax = plt.subplots(figsize=(10, 5))

ax.hist(edad, bins=range(0, 121, 5), color='#3266ad', alpha=0.75,
        edgecolor='white', linewidth=0.5, label='Distribución de edades')

# Línea de la media
ax.axvline(media, color='#E24B4A', linewidth=2, linestyle='--',
           label=f'Media: {media:.1f} años')

# Banda de ±1 desviación estándar
ax.axvspan(media - desv_std, media + desv_std,
           alpha=0.15, color='#EF9F27',
           label=f'±1   ({media - desv_std:.1f} - {media + desv_std:.1f} años)')

ax.set_title('Varianza y desviación estándar - edad de personas desaparecidas', fonts
ax.set_xlabel('Edad (años)', fontsize=11)
ax.set_ylabel('Número de personas', fontsize=11)
ax.legend(fontsize=10)
ax.yaxis.set_major_formatter(plt.FuncFormatter(lambda x, _: f'{int(x):,}'))
```

```
plt.tight_layout()
plt.savefig('variabilidad_edad.png', dpi=150, bbox_inches='tight')
plt.show()
```

```
Varianza:            292.7119 años
Desviación estándar: 17.1088 años
Media:               31.71 años
```

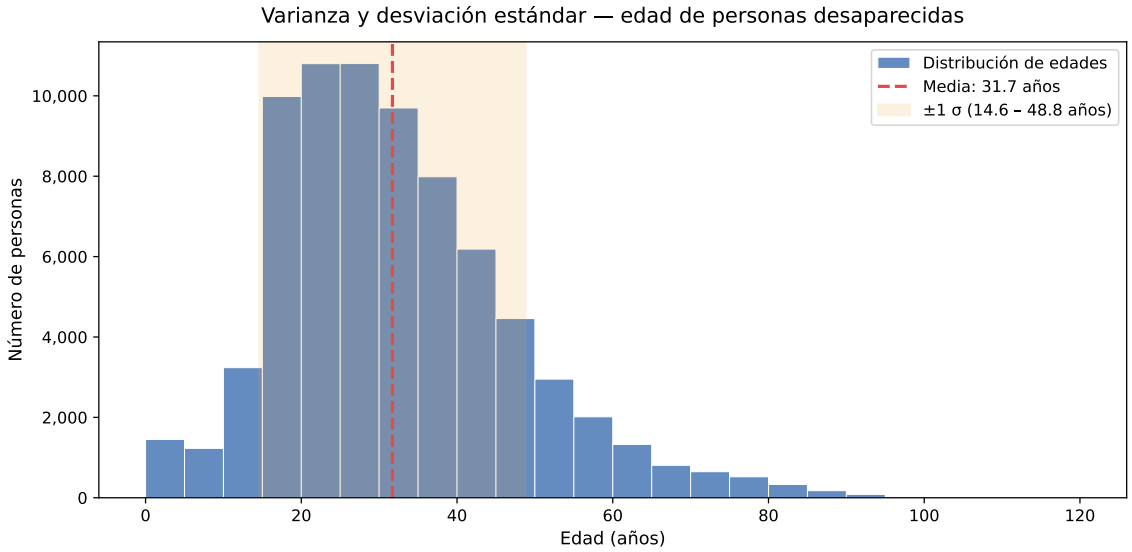

Cuartiles, Rango e IQR

- **Cuartiles** El primer cuartil (Q1) de 21 años indica que el 25 % de las personas desaparecidas tenía 21 años o menos al momento de su desaparición, lo que evidencia una concentración significativa de casos en población joven. El tercer cuartil (Q3) de 40 años señala que el 75 % de los registros corresponde a personas de 40 años o menos, confirmando que la desaparición de personas en México afecta predominantemente a individuos en etapa productiva y juvenil.

- **Rango Intercuartílico (IQR)** El IQR de 19 años representa la amplitud del 50 % central de los datos, es decir, la mitad de las personas desaparecidas tenía entre 21 y 40 años,mostrando que la mayor concentración de edades se encuentra dentro de ese intervalo.
- **Rango y valores atípicos** Los límites calculados a partir del IQR establecen que valores fuera del rango de -7.50 a 68.50 años se consideran atípicos estadísticamente. Dado que una edad negativa no tiene interpretación posible, el límite inferior efectivo es 0 años. Esto significa que cualquier persona registrada con más de 68 años representa un caso atípico dentro del dataset, esto puede implicar que dichos casos sean errores o que se trate de desapariciones menos frecuentes en grupos de edad avanzada.

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Cargar CSV limpio
df = pd.read_csv('dataset_limpio.csv', encoding='latin1')
df['Edad'] = pd.to_numeric(df['Edad'], errors='coerce')
edad = df['Edad'].dropna()

# Medidas
q1  = np.quantile(edad, 0.25)
q3  = np.quantile(edad, 0.75)
iqr = q3 - q1
low  = q1 - 1.5 * iqr
high = q3 + 1.5 * iqr

print(f"Q1:    {q1:.2f} años")
print(f"Q3:    {q3:.2f} años")
print(f"IQR:   {iqr:.2f} años")
print(f"Límite inferior: {low:.2f} años")
```

```python
print(f"Límite superior: {high:.2f} años")

# Boxplot
plt.figure()
plt.boxplot(edad, vert=True)
plt.title(f"Boxplot edad: IQR={iqr:.2f}, límites [{low:.2f}, {high:.2f}]")
plt.ylabel("Edad (años)")
plt.tight_layout()
plt.show()
```

```
Q1:    21.00 años
Q3:    40.00 años
IQR:   19.00 años
Límite inferior: -7.50 años
Límite superior: 68.50 años
```

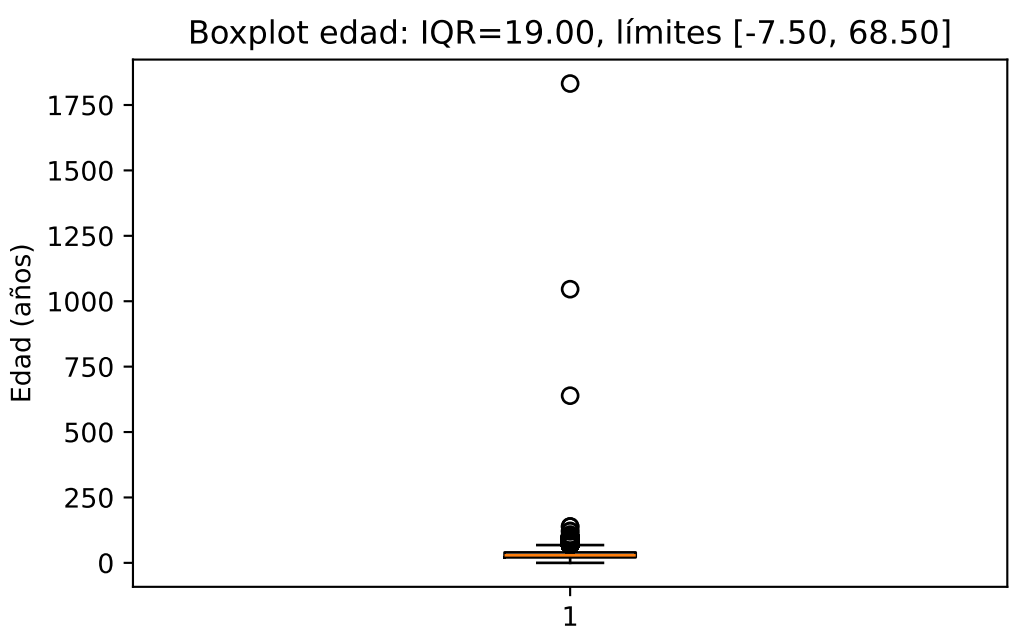

Medidas de heterogeneidad

Medidas de concentración

Correlación

- Generar la matriz de correlación (heatmap)
- Indicar correlaciones más fuertes y más débiles

Hallazgos importantes y limitaciones del análisis

1. Alto porcentaje de datos faltantes en la columna Fecha de desaparición El 80 % de los registros carece de fecha de desaparición, lo que limita significativamente el análisis temporal y la identificación de tendencias a lo largo del tiempo.
2. Concentración de desapariciones en población joven (moda: 18 años) La distribución de edades muestra que la moda es de 18 años, lo que indica una concentración preocupante en población adolescente.
3. Rango típico de riesgo: entre 14 y 48 años Encontramos una desviación estándar de 17 años sobre la media de 31 años, el perfil típico de persona desaparecida oscila entre los 14 y 48 años. Los cuartiles confirman que el 50 % central de los casos tiene entre 21 años (Q1) y 40 años (Q3), afectando principalmente a población en etapa productiva y juvenil.
4. Presencia de valores atípicos extremos en la variable Edad

Reporte final: hallazgos y limitaciones

Entregar un reporte en PDF que incluya: - Objetivo y preguntas de análisis - Descripción del dataset asignado al equipo - Al menos 8 hallazgos principales sustentados con evidencia gráfica o tablas - Limitaciones del análisis: calidad de los datos, sesgos, variables faltantes y decisiones de limpieza - Conclusión.